


Pornind de la un fișier text de tip Ebook să se identifice și să se afișeze cu ajutorul Spark utilizând limbajul python cele mai des utilizate cuvinte din text (se ignoră entitățile semantice de legătură).



Notite

1. Gasesti un site si descarci o carte: <https://www.epubbooks.com/>
2. Gasesti un converter catre text <https://cloudconvert.com/epub-to-txt>
3. Din stanga jos descarci pyspark daca este nevoie
4. Creezi fisierul si ii dai path-ul(unde scrie acolo 4300-0.txt) si creezi si fisierul result.txt
5. Daca nu gasese fisierul pui fisierul cu cartea intr-un director ca functia spark_context cauta in foldere dupa fisier

```
import os

from pyspark import *
from pyspark.streaming import StreamingContext

os.environ["PYSPARK_PYTHON"] = "python3"
os.environ["PYSPARK_DRIVER_PYTHON"] = "python3"

def runMain():

    ctx = SparkContext(appName="streaming", master="local[*]")
    ctx.setLogLevel("WARN")

    spark_context = StreamingContext(ctx, 1)
```

```
lines_data = spark_context.textFileStream("4300-0.txt")

words = lines_data.flatMap(lambda line: line.split(" ")).filter(lambda word:
word != '')

mapped_words = words.map(lambda word: (word, 1))
words_count = mapped_words.reduceByKey(lambda x, y: x+y)

words_count.saveAsTextFiles("result.txt")
spark_context.start()
spark_context.awaitTermination()
spark_context.stop()

if __name__ == '__main__':
    runMain()
```